

What Is the Book? Detecção de livros com HOG e classificadores supervisionados

Ighor Tatsch Telles

Escola Politécnica – PUCRS

Introdução à Visão Computacional

ighor.tatsch@edu.pucrs.br

Abstract. This paper presents a book detector based on spatial normalization, contrast enhancement, Histogram of Oriented Gradients descriptors, sliding windows, and non-maximum suppression. Logistic regression and a multilayer perceptron are compared using a public dataset with separate training, validation, and test splits. Thresholds are selected to maximize validation precision subject to recall of at least 50%, then frozen for final testing. Stronger logistic regression regularization yields 4.76% precision and 50.65% recall on validation. On 22 test images with 37 annotated books, the selected model achieves 4.00% precision and 51.35% recall, with 19 true positives, 456 false positives, and 18 false negatives. The prototype demonstrates the complete detection pipeline, although the high number of false positives limits practical use.

Resumo. Este artigo apresenta um detector de livros baseado em normalização espacial, realce de contraste, descritores de histogramas de gradientes orientados, janelas deslizantes e supressão de máximos. Comparam-se regressão logística e perceptron multicamadas em um conjunto público dividido em treinamento, validação e teste. Selecionam-se limiares que maximizam a precisão na validação, sujeitos a revocação mínima de 50%, e congelam-se essas escolhas para o teste final. A regressão com maior regularização obtém precisão de 4,76% e revocação de 50,65% na validação. Nas 22 imagens de teste, com 37 livros anotados, o modelo selecionado alcança precisão de 4,00% e revocação de 51,35%, com 19 acertos, 456 falsos positivos e 18 falsos negativos. O protótipo demonstra o pipeline completo, embora os numerosos falsos positivos limitem sua aplicação prática. **Palavras-chave:** detecção de objetos; livros; HOG; regressão logística; MLP.

1 Introdução

Localizar livros em imagens exige reconhecer sua aparência e determinar sua posição. Capas com diferentes texturas, proporções e orientações, juntamente com bordas presentes no fundo, dificultam distinguir livros de outras regiões. Uma classificação correta de um recorte não garante, por si só, que a caixa correspondente localize adequadamente um objeto na imagem completa.

O projeto *What Is the Book?* investiga essa

tarefa com técnicas clássicas de visão computacional. Sua saída consiste em caixas delimitadoras de livros nas imagens; não se pretende identificar títulos, reconhecer texto ou consultar catálogos. O desenvolvimento atende ao Trabalho I de Introdução à Visão Computacional da PUCRS, que exige utilização de OpenCV, características extraídas das imagens, avaliação quantitativa e uma prova de conceito, permitindo MLP como arquitetura neural [7].

O objetivo é construir e avaliar um pipeline baseado em HOG, comparando regressão lo-

gística e MLP. Examina-se também o efeito de regularização, amostragem de fundo e mineração de negativos difíceis. A contribuição é uma implementação rastreável que relaciona a geração geométrica das regiões candidatas aos erros efetivos de classificação e localização.

2 Fundamentação

O descritor HOG agrega direções de gradiente em células espaciais e normaliza histogramas em blocos locais. Essa representação descreve contornos e padrões de intensidade [5]. Neste projeto, ela é aplicada a recortes de livros e fundo. A transferência do descritor para esse domínio é uma escolha experimental; os resultados de outros problemas não asseguram desempenho na detecção de livros.

A regressão logística aprende uma função linear sobre as características padronizadas. O parâmetro C controla inversamente a força da regularização: reduzir C restringe mais os coeficientes. O MLP introduz transformações não lineares entre os descritores e a decisão. Ambos recebem características previamente extraídas, mantendo a extração visual separada do aprendizado supervisionado.

A busca por janelas transforma classificadores de recortes em detectores. Como diferentes janelas podem cobrir o mesmo objeto, a supressão de máximos não locais, ou NMS, elimina propostas redundantes por pontuação e sobreposição. Contudo, ela não corrige automaticamente caixas de fundo com alta pontuação.

O NMS é uma etapa de pós-processamento: mantém a caixa de maior pontuação e suprime propostas com sobreposição acima do limiar, repetindo a seleção nas caixas restantes [2]. Seu uso se justifica pela redundância produzida pela busca em diferentes posições e escalas. O material *Histogram of Oriented Gradients (HOG) in Computer Vision* é incluído como leitura complementar sobre o descritor [1].

3 Materiais e metodologia

3.1 Dados e separação experimental

Utiliza-se o conjunto público *Day 24 Book Detection*, disponibilizado no Roboflow Universe e identificado no repositório [6]. As anotações locais seguem o formato COCO, com caixas da categoria `Book`. A Tabela 1 apresenta as contagens registradas na documentação do projeto.

Tabela 1: Divisões do conjunto de dados.

Divisão	Imagens	Livros
Treinamento	156	204
Validação	45	77
Teste	22	37
Total	223	318

Somente treinamento é usado para aprender os modelos, estimar tamanhos das janelas e minerar negativos difíceis. A validação serve à seleção dos limiares e à comparação das variantes. Após essas escolhas, os quatro modelos são avaliados nas 22 imagens de teste, sem treinamento, mineração ou ajuste adicional. As métricas de validação e de teste são apresentadas separadamente: as primeiras orientam a seleção; as últimas avaliam as configurações congeladas em uma divisão não utilizada nesses ajustes.

3.2 Pipeline e pré-processamento

O fluxo implementado é: imagem, normalização espacial, geração de janelas, pré-processamento dos recortes, HOG, classificação em lotes, filtragem por limiar, NMS e conversão das caixas para a imagem original.

O maior lado da imagem é normalizado para 640 pixels, preservando sua proporção. Essa escolha torna a resolução de busca consistente entre imagens e limita o custo da varredura em

entradas de alta resolução. As caixas anotadas acompanham essa transformação; coordenadas externas são limitadas à região visível, e caixas sem área são descartadas. Na implementação, utiliza-se interpolação por área quando a imagem é reduzida e interpolação linear quando é ampliada. A normalização pode remover detalhes de livros pequenos, de modo que 640 pixels representa uma escolha operacional, não uma resolução ótima demonstrada.

Cada recorte é convertido para escala de cinza. A conversão reduz a entrada a um canal e concentra a representação nas variações de intensidade usadas para calcular os gradientes do HOG. Essa escolha é coerente com o objetivo de representar bordas e textura, mas descarta informações de cor que poderiam ajudar a diferenciar determinadas capas do fundo.

Em seguida, aplica-se CLAHE (*Contrast Limited Adaptive Histogram Equalization*), com limite de contraste 2,0 e grade de 8×8 regiões. A equalização local procura evidenciar detalhes em partes do recorte com baixo contraste, enquanto o recorte dos histogramas limita a amplificação excessiva de contraste e ruído [3, 4]. Essa técnica é escolhida para tornar contornos de livros mais perceptíveis quando a iluminação varia dentro da imagem, antes do cálculo dos gradientes. O limite não elimina a possibilidade de realçar texturas do fundo, e o efeito isolado do CLAHE sobre as métricas não foi medido por ablação.

Após o realce, o recorte é redimensionado para 96×128 pixels, com interpolação por área. O tamanho fixo assegura a mesma organização espacial de células e blocos e um vetor de dimensão constante, requisito para fornecer entradas compatíveis aos dois classificadores. Diferentemente da normalização da imagem completa, essa transformação não preserva necessariamente a proporção do recorte: a padronização facilita o aprendizado, mas pode deformar contornos e perder detalhes. O mesmo procedimento é aplicado no treinamento e na inferência para manter a representação consistente.

O HOG usa células 8×8 , blocos 16×16 , deslocamento de blocos 8×8 e nove orientações. Há 11 posições horizontais e 15 verticais de blocos. Cada bloco reúne quatro células, produzindo

$$d = 11 \cdot 15 \cdot 4 \cdot 9 = 5940 \quad (1)$$

características por recorte. O tamanho fixo permite compartilhar a mesma matriz entre classificadores, mas deforma recortes cuja proporção difere da janela HOG.

3.3 Construção dos exemplos

Cada caixa de livro gera um recorte positivo. Acrescentam-se até duas janelas candidatas com interseção sobre união (IoU) de pelo menos 0,60 com essa caixa, aproximando exemplos de treinamento das regiões encontradas na inferência. A IoU entre duas caixas A e B é definida como

$$\text{IoU}(A, B) = \frac{|A \cap B|}{|A \cup B|}. \quad (2)$$

Os negativos são janelas sorteadas de fundo. Para evitar rotular fragmentos de livros como negativos, a soma das áreas de interseção com caixas anotadas, dividida pela área da janela, deve ser no máximo 1%. Esse critério é mais adequado que usar apenas IoU baixa: uma pequena janela dentro de um livro grande pode ter IoU baixa e ainda conter exclusivamente o objeto.

Com até 15 negativos por imagem, a documentação registra 2740 recortes, sendo 595 positivos e 2145 negativos. A rodada principal utiliza até 30 negativos e registra 4885 exemplos comuns aos modelos de referência, regularizado e MLP. A semente 42 controla a amostragem. A quantidade solicitada é um limite, pois depende de janelas válidas e da remoção de duplicatas.

3.4 Janelas e classificadores

Os tamanhos-base são estimados por K-Means sobre larguras e alturas das caixas normali-

zadas de treinamento, em escala logarítmica. Utilizam-se até 12 grupos, semente 42 e dez inicializações. Na inferência, os tamanhos são multiplicados por 0,8, 1,0 e 1,25. A busca inclui posições nas bordas e uma janela da imagem inteira. O passo padrão máximo é 32 pixels, reduzido em janelas pequenas, com mínimo padrão de 16 pixels.

Os descritores passam por `StandardScaler`, ajustado no treinamento e reutilizado na inferência. A regressão utiliza balanceamento das classes, até 3000 iterações e $C = 1$ na referência ou $C = 0,01$ na variante regularizada. O MLP possui duas camadas ocultas, com 128 e 64 neurônios, até 1000 épocas e parada antecipada. Sua validação interna para parada antecipada utiliza uma parcela dos recortes de treinamento, distinta da divisão externa de validação.

A padronização das características centraliza cada componente e ajusta sua escala pelo desvio padrão observado no treinamento. Isso reduz diferenças de escala entre entradas, tornando mais consistente a ação da regularização na regressão e o ajuste dos pesos do MLP. Os mesmos parâmetros são reutilizados em validação e teste, sem recalculá-los nessas divisões. Trata-se de uma transformação dos descritores, posterior ao pré-processamento das imagens; não foi realizada uma comparação isolada com a ausência de padronização.

As janelas são classificadas em lotes de até 256. A regressão utiliza a margem de `decision_function`; o MLP utiliza $p(\text{livro}) - 0,5$. Logo, os limiares têm escalas distintas. Após filtrar pela pontuação, aplica-se NMS com IoU 0,35. Esse valor controla redundância, enquanto a IoU 0,50 usada na avaliação controla o acerto de localização.

3.5 Negativos difíceis e variantes

A mineração limitada seleciona 30 imagens de treinamento e até oito regiões de fundo de alta pontuação por imagem, usando o detector de referência e semente 42. Excluem-se

regiões cuja ocupação anotada exceda 1%. O manifesto registra 172 negativos adicionais, totalizando 5057 exemplos na variante correspondente. A regressão dessa variante usa $C = 1$, mantendo separadas as alterações de regularização e mineração.

Comparam-se quatro condições: regressão de referência com 30 negativos, regressão com $C = 0,01$, regressão acrescida de negativos difíceis e MLP com os mesmos recortes aleatórios da referência. Não foi executada a variante de 60 negativos por imagem.

4 Protocolo de avaliação

As detecções são ordenadas por pontuação e associadas às anotações por correspondência um a um. Uma previsão conta como verdadeiro positivo (TP) quando alcança IoU de pelo menos 0,50 com uma anotação ainda disponível; escolhe-se a de maior IoU. Previsões restantes são falsos positivos (FP), e anotações sem correspondência são falsos negativos (FN).

As contagens são agregadas separadamente nas 45 imagens de validação e nas 22 imagens de teste antes do cálculo das métricas:

$$P = \frac{TP}{TP + FP}, \quad R = \frac{TP}{TP + FN}, \quad (3)$$

$$F_1 = \frac{2PR}{P + R}. \quad (4)$$

Não se calcula a média de precisões individuais das imagens.

Para a regressão, a rodada principal avalia os limiares 0; 0,5; 1; 2; 3; 4; 6; 8; 10; 12; 15; 20 e 25. Para o MLP, avalia 0; 0,1; 0,2; 0,3; 0,4; 0,45; 0,48; 0,49; 0,495 e 0,499. Seleciona-se a maior precisão entre configurações com $R \geq 0,50$, com desempate por maior F_1 e menor limiar. A restrição evita selecionar um detector que quase não recupera livros apenas para reduzir falsos alarmes.

Os modelos compartilham a extração HOG dos lotes de validação. Em cada modelo, previsões e NMS são calculados no menor limiar;

os demais resultados são obtidos filtrando as caixas mantidas. Isso preserva o comportamento do NMS guloso ordenado por pontuação e evita repetir a extração para cada limiar.

4.1 Avaliação final com protocolo congelado

A avaliação de teste carrega os modelos registrados no manifesto de validação e utiliza apenas um limiar por modelo: 10 para a referência, 6 para a regressão regularizada, 4 para a regressão com negativos difíceis e 0,495 para o MLP. Mantêm-se os pesos, as configurações de janelas salvas, o passo máximo 32, o NMS e a IoU de correspondência de 0,50. Não se executa uma busca de limiares no teste, nem se impõe novamente a restrição de revocação mínima para selecionar um vencedor nessa divisão.

A recomendação permanece a regressão `logistic_regression_004`, escolhida na validação. O relatório final registra hashes SHA-256 dos arquivos dos modelos e das imagens e anotações, além das métricas e do tempo. Quando o protocolo é idêntico, a implementação reutiliza o relatório salvo sem repetir a inferência. Essa rastreabilidade permite identificar precisamente quais dados e modelos deram origem aos resultados.

5 Resultados e discussão

5.1 Seleção na validação

A regressão com $C = 0,01$ apresentou a melhor precisão entre as configurações elegíveis: 39 TP, 780 FP e 38 FN. Em relação à referência, os FP diminuíram 12,9%, com perda de um TP. A precisão aumentou aproximadamente 0,49 ponto percentual, e o F_1 passou de 0,07897 para 0,08705. O modelo recomendado nessa rodada é `logistic_regression_004`, com limiar 6.

O MLP recuperou 43 livros, quatro a mais que a regressão regularizada, mas produziu 948 FP e precisão menor. Seu limiar 0,495 equivale a aceitar probabilidades de pelo menos 99,5%. Mesmo esse corte elevado não impediu numerosos falsos alarmes, evidenciando que a probabilidade estimada não assegura uma localização correta no protocolo empregado.

A mineração limitada piorou o ponto selecionado: os mesmos 39 TP foram acompanhados de 2843 FP. O experimento não sustenta atribuir uma causa única à piora. A quantidade e diversidade dos negativos, a alteração da distribuição de exemplos e o reajuste do limiar são hipóteses para investigação. Não se pode concluir, a partir dessa rodada, que mineração de negativos difíceis seja inadequada em geral.

5.2 Compromisso entre precisão e revocação

Na regressão regularizada, o limiar 10 produz 19 TP, 102 FP e 58 FN: precisão de 15,70% e revocação de 24,68%. Apesar de sua precisão maior, esse ponto é excluído pelo requisito de recuperar pelo menos metade dos livros. O melhor resultado depende, portanto, da regra de seleção e da grade testada; não constitui um ótimo global demonstrado.

O histórico também registra regressão com até 15 negativos e limiar zero, com 53 TP, 8567 FP e 24 FN. Ao usar até 30 negativos e limiar 10, obtiveram-se 40 TP e 896 FP. A redução de 89,5% dos falsos positivos acompanha perda de 13 acertos. Como treinamento e limiar mudam conjuntamente nessa comparação, ela não isola o efeito da quantidade de negativos.

A referência da rodada principal foi carregada da versão `logistic_regression_002`; a versão 003 preserva sua avaliação na grade ampliada. As versões 004 e 005 correspondem aos novos treinos de regularização e mineração. Esse versionamento evita confundir novas avaliações com novos modelos.

Tabela 2: Resultados de validação com IoU mínima de 0,50 e revocação mínima de 50%.

Experimento	Limiar	TP	FP	FN	Precisão (%)	Revocação (%)	F_1
Regressão: referência	10	40	896	37	4,27	51,95	0,07897
Regressão: $C = 0,01$	6	39	780	38	4,76	50,65	0,08705
Regressão: negativos difíceis	4	39	2843	38	1,35	50,65	0,02636
MLP: mesmos recortes	0,495	43	948	34	4,34	55,84	0,08052

5.3 Resultados finais no teste

A Tabela 3 apresenta a avaliação dos quatro modelos com seus limiares congelados.

O modelo recomendado na validação obteve 19 TP, 456 FP e 18 FN no teste, com precisão de 4,00%, revocação de 51,35% e F_1 de 0,07422. Frente à referência no mesmo teste, preservou os 19 acertos e reduziu os FP de 499 para 456, uma diminuição de 8,6%. A maior regularização apresentou, portanto, menos falsos alarmes nas duas divisões observadas, embora a ausência de repetições e intervalos de confiança impeça afirmar significância estatística dessa diferença.

Comparando as divisões, a precisão da regressão regularizada caiu de 4,76% para 4,00%, aproximadamente 0,76 ponto percentual, e o F_1 caiu de 0,08705 para 0,07422. A revocação passou de 50,65% para 51,35%, diferença de cerca de 0,70 ponto percentual. Como as divisões possuem quantidades diferentes de imagens e livros, suas contagens absolutas de TP e FP não devem ser interpretadas diretamente como melhora ou piora; as métricas normalizadas expressam melhor essa comparação.

O MLP, que recuperou mais livros na validação, empatou com a referência e a regressão regularizada em 19 acertos no teste, com 501 FP. A vantagem de revocação observada na validação não se repetiu nessa divisão. Já a regressão com negativos difíceis recuperou 22 livros, a maior revocação do teste (59,46%), mas gerou 1560 FP e precisão de apenas 1,39%. Sua recuperação adicional veio acompanhada de muitos falsos alarmes, mantendo o compromisso desfavorável observado na validação.

Esses resultados não foram utilizados para redefinir a recomendação ou reajustar os limiares. A baixa precisão final confirma que a configuração escolhida ainda apresenta limitações importantes para uso prático, mesmo recuperando aproximadamente metade dos livros anotados.

5.4 Cobertura geométrica e limitações

A documentação registra que 75 dos 77 livros de validação possuem pelo menos uma janela candidata com IoU de 0,50, correspondendo a 97,4% de cobertura. Trata-se de um limite geométrico da recuperação para essas janelas, calculado independentemente da classificação. A diferença em relação aos aproximadamente 51% de revocação do modelo selecionado mostra que oferecer regiões adequadas não basta para aceitá-las e preservá-las até a saída.

A precisão de 4,76% na validação significa que a maior parte das caixas previstas não corresponde a livros pelo critério de avaliação: há 20 FP para cada TP no ponto selecionado. No teste, a precisão de 4,00% corresponde a 24 FP por TP, reforçando essa limitação. O detector demonstra a execução completa, mas ainda exige revisão humana substancial. Possíveis dificuldades incluem semelhança entre contornos do fundo e dos livros, distorção dos recortes, pequena quantidade de imagens e eventuais livros não anotados em regiões tratadas como fundo.

Essas explicações são hipóteses, pois não há análise categorizada dos erros nem ablação das etapas de pré-processamento. Também não foram registrados intervalos de confiança ou re-

Tabela 3: Resultados finais nas 22 imagens de teste, com 37 livros anotados e IoU mínima de 0,50. Os limiares foram definidos exclusivamente na validação.

Experimento	Limiar	TP	FP	FN	Precisão (%)	Revocação (%)	F_1
Regressão: referência	10	19	499	18	3,67	51,35	0,06847
Regressão: $C = 0,01$	6	19	456	18	4,00	51,35	0,07422
Regressão: negativos difíceis	4	22	1560	15	1,39	59,46	0,02718
MLP: mesmos recortes	0,495	19	501	18	3,65	51,35	0,06822

petições com múltiplas sementes. A seleção e comparação na mesma validação pode favorecer configurações específicas dessas imagens. O teste com escolhas congeladas fornece uma avaliação independente dos ajustes realizados, mas contém apenas 22 imagens e 37 livros, limitando a extensão das conclusões sobre generalização. Após observar seus resultados, novos ajustes precisam de outro protocolo de avaliação independente; essa mesma divisão não deve ser reutilizada como teste final não observado.

6 Prova de conceito e reprodução

A implementação usa Python, OpenCV e scikit-learn. O notebook `src/main.ipynb` organiza os dados, o treinamento, as métricas, a comparação dos modelos e exemplos de detecção. A aplicação Streamlit em `src/app/` constitui a prova de conceito: recebe uma imagem e mostra as caixas produzidas pelas versões salvas da regressão e do MLP.

Cada versão prevê independentemente sobre a mesma imagem, sem votação entre modelos e sem novo treinamento. A interface permite demonstrar o fluxo completo com uma imagem previamente obtida ou nova. Essa demonstração funcional complementa as métricas, mas não substitui a avaliação em um conjunto anotado.

Os arquivos de modelos preservam padronização, configuração das janelas, limiar selecionado e metadados de treinamento. A rodada de treinamento e vali-

dação pode ser reproduzida pelo módulo `src.evaluation.run_precision`. Os CSVs registram todas as contagens por limiar, e o manifesto associa resultados a modelos, exemplos e negativos minerados. O módulo `src.evaluation.test_set` executa ou consulta a avaliação congelada, registrada em `test_evaluation_001.json`. O notebook também apresenta as tabelas finais e o gráfico de comparação entre validação e teste, exportado como `comparacao_valid_test.png`. Os PNGs em `docs/results/` oferecem ilustrações complementares no repositório; o presente documento é autossuficiente para compilação.

7 Conclusão

Foi desenvolvido um detector de livros que combina pré-processamento com OpenCV, HOG, classificação supervisionada, janelas deslizantes e NMS. A metodologia explicita a diferença entre classificar recortes e localizar objetos, utiliza apenas treinamento para gerar exemplos, seleciona configurações na validação e realiza a avaliação final no teste com pesos e limiares congelados.

Na validação, a regressão logística com $C = 0,01$ e limiar 6 alcançou a melhor precisão sob revocação mínima de 50%: 4,76% de precisão e 50,65% de revocação. Mantida essa escolha, o teste final produziu 19 acertos, 456 falsos positivos e 18 falsos negativos, com precisão de 4,00%, revocação de 51,35% e F_1 de 0,07422. O MLP não manteve sua vanta-

gem de recuperação no teste, e a mineração limitada recuperou mais livros à custa de muitos falsos alarmes. A avaliação final reforça que a elevada incidência de falsos positivos limita o uso prático, embora a prova de conceito permita demonstrar o funcionamento da solução.

Como continuidade, propõem-se inspeção e categorização dos erros, ampliação e revisão das anotações, avaliação de preservação das proporções nos recortes e mineração mais diversificada. Essas alterações devem ser investigadas em treinamento e validação, com uma nova avaliação independente após a exposição aos resultados do teste atual. As métricas finais registradas devem permanecer associadas ao protocolo e aos modelos efetivamente avaliados.

Referências

- [1] Towards Data Science. *Histogram of Oriented Gradients (HOG) in Computer Vision*. Disponível em: <https://towardsdatascience.com/histogram-of-oriented-gradients-hog-in-computer-vision-azec66f6e671/>
Referência complementar indicada pelo autor.
- [2] Ultralytics. *Non-Maximum Suppression (NMS)*. Disponível em: <https://www.ultralytics.com/glossary/non-maximum-suppression-nms>. Acesso em: 6 out. 2026.
- [3] Zavala, F. (2025). *Histogram equalization CLAHE algorithm*. ImageCraft, Medium, 17 mar. Disponível em: <https://medium.com/imagecraft/histogram-equalization-clahe-algorithm-8841d402fc76>. Acesso em: 6 out. 2026.
- [4] OpenCV. *Histograms – 2: Histogram Equalization*. Documentação oficial. Disponível em: https://docs.opencv.org/4.x/d5/daf/tutorial_py_histogram_equalization.html. Acesso em: 6 out. 2026.
- [5] Dalal, N. e Triggs, B. (2005). Histograms of Oriented Gradients for Human Detection. *IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, v. 1, p. 886–893. DOI: 10.1109/CVPR.2005.177.
- [6] Roboflow Universe. *Day 24 Book Detection*. Conjunto de dados público identificado no README do projeto. Disponível em: <https://universe.roboflow.com/hifsaiftikhar77-gmail-com/day-24-book-detection>.
- [7] Amaral, D. O. F. do. (2026). *Introdução à Visão Computacional: Trabalho I*. Escola Politécnica, Pontifícia Universidade Católica do Rio Grande do Sul. Enunciado disponibilizado no diretório docs/ do projeto.
- [8] *What Is the Book?* (2026). Documentação e artefatos locais: README, código-fonte, notebook, relatórios, CSV, manifesto, `precision_run_001.json` e relatório final `test_evaluation_001.json`. Resultados de validação e teste de 6 de outubro de 2026.